


Rapport: California Housing - Klassificeringsanalys

1) Mål & valt spår

I denna uppgift agerar jag som dataanalytiker på ett konsultföretag som stödjer kommuner och fastighetsaktörer i datadrivna beslut. Jag utvecklar en maskininlärningsmodell i Scikit-learn baserad på California Housing-datasetet. Fokus ligger på ett klassificeringsproblem ("Spår B") där målet är att identifiera områden med bostadspriser i topp 20 %, samt analysera mönster för möjlig segmentering. Målet är inte att förutsäga exakta priser, utan att skapa ett tillförlitligt verktyg för att identifiera högprisområden utifrån deras egenskaper. Verktöget antas användas för initial screening inför vidare utvärdering vilket kommer att påverka beslut som tas för att optimera lösningen.

2) Kort data-insikt (EDA)


Korrelationsanalysen visar att medianinkomst har den starkaste positiva korrelationen med målvariabeln *high_value* (0,54), vilket tyder på att områden med högre inkomster oftare sammanfaller med högprisområden, även om undantag förekommer. Näst starkast korrelation uppvisar medianålder (0,10). Övriga variabler har mycket låg korrelation med målvariabeln.



Medianinkomst inom lågpris (0) respektive högprisområden (1)

Den geografiska analysen visar att högprisområden främst finns längs kusten och kring stadskärnor, medan lågprisområden

dominerar inlandet. Cirka 5 % av bostäder i inlandet klassas som högpris, jämfört med 25–30 % nära havet och i Bay Area. Ömråden avviker med cirka 80 %, men bygger på få observationer (8), vilket stärker sambandet mellan läge och pris.



Geografisk spridning mellan lågpris och högprisområden

3) Metod (ML-flöde)

Datan delas i tränings- och testmängd (80/20) för supervised learning. Eftersom endast 20 % är högprisområden används stratifierad sampling för att bevara klassfördelningen och undvika snedvriden utvärdering.

Följande modeller används baserat på deras egenskaper: *Logistic Regression* (tolkningsbar baseline), *Decision Tree* (fångar icke-linjära samband), *Random Forest* (minskar överanpassning och ökar noggrannhet) samt *Dummy-klassificerare* (referensnivå).

Prestanda utvärderas med 5-fold cross validation och medelvärden av Accuracy, Precision, Recall och F1-score.

Accuracy – andel korrekt klassificerade observationer

Precision – andel förväntade positiva fall som är korrekta

Recall – andel faktiska positiva fall som identifierats korrekt

F1-score – harmoniskt medelvärde av precision och recall.

	Model	Accuracy	Precision	Recall	F1
3	Random Forest	0.93	0.88	0.73	0.80
2	Decision Tree	0.88	0.71	0.72	0.71
1	Logistic Regression	0.89	0.81	0.58	0.68
0	Dummy Baseline	0.68	0.21	0.21	0.21

Resultat av modellutvärdering med 5-fold Cross Validation

4) Resultat

Random Forest presterade bäst över samtliga måtvärden: högst Accuracy (0,93), Precision (0,88) och F1-score (0,80), samt stark Recall (0,73). Detta visar på en god balans mellan att identifiera högprisområden och minimera felklassificeringar.

Modellen valdes för vidare optimering med F1-score som primärt mått. Hyperparametrar tunades med GridSearchCV (max_depth=20, min_samples_leaf=2, min_samples_split=2, n_estimators=200, class_weight=balanced), vilket resulterade i en relativt komplex men regulariserad modell anpassad för klassobalans.

Efter tuning ökade Accuracy från 0,93 till 0,99. Modellen presterar mycket bra för lågpris (Recall 0,99) och även starkt för högpris (Recall 1,0, Precision 0,97). Samtidigt gjordes fler fel där lågpris klassificerades som högpris (FP=106) än tvärtom (FN=11), vilket indikerar något bättre träffsäkerhet för lågpris.

För att prioritera att fånga högprisområden sänktes beslutströskeln från 0,5 till 0,4, vilket ökade Recall på bekostnad av Precision. Detta är motiverat då missade högprisområden anses mer kostsamma än falska positiva.

Slutlig test-prestanda

Slutlig prestanda visar god generalisering (CV: 0,8081, test: 0,8063), vilket tyder på att modellen presterar ungefär lika bra på osedd data som på träningsdata.

Accuracy = 0.91 (0.99)	Precision	Recall	F1-score
Lågpris (Klass 0)	0.96 (1.0)	0.94 (0.99)	0.95 (1.0)
Högpris (Klass 1)	0.76 (0.97)	0.83 (1.0)	0.79 (0.98)

Jämfört med träningsdata försämrars resultaten något, särskilt för högpris där Precision sjunker till 0,76. Recall förblir dock relativt hög (0,84), i linje med vald trade-off. Antalet felklassificeringar ökar (FP: 106 vs 214, FN: 11 vs 140), vilket tyder på en svaghet i modellens förmåga att stabilt identifiera högprisområden trots threshold-justeringen.

5) Rekommendation

Random Forest är det mest lämpliga valet då modellen effektivt fångar icke-linjära samband och ger en välavvägd balans mellan precision och recall, vilket är centralt för att identifiera högprisområden. Nackdelen är lägre tolkningsbarhet på grund av modellens komplexitet.

Decision Tree erbjuder högre transparens men sämre generaliseringsförmåga, medan Logistic Regression är enklare och tolkningsbar men mindre lämpad för att fånga datans mer komplexa, icke-linjära mönster.

6) Risker & begränsningar

Trots god prestanda finns flera begränsningar. Random Forest har låg tolkningsbarhet, vilket försvårar insikt i vilka faktorer som driver klassificeringen. Det finns även risk för överanpassning då resultaten är betydligt högre på träningsdata än på testdata, även om cross-validation indikerar god generalisering.

Klassobalansen och den sänkta threshold innebär en medveten trade-off där fler högprisområden felklassificeras, vilket kan påverka tillförlitligheten i praktiken.

Prestandan är dessutom beroende av datakvalitet och variabelval. Viktiga faktorer kan saknas, vilket begränsar modellens förmåga. Att inkludera fler relevanta variabler och iterativt förbättra modellen kan stärka dess stabilitet och träffsäkerhet över tid.

7) Övervakad inlärning


Övervakad inlärning används för att identifiera strukturer och mönster i data utan fördefinierade målvariabler. I denna uppgift används K-Means som ett komplement till

EDA för att upptäcka naturliga kluster och möjliggöra segmentering av områden med liknande egenskaper.

Till skillnad från PCA, som reducerar dimensioner för att maximera varians, delar K-Means upp data i ett fördefinierat antal kluster där varje datapunkt tilldelas det kluster vars centroid ligger närmast. En begränsning är att metoden alltid identifierar mönster, även om dessa inte är meningsfulla. K-Means lämpar sig främst för numeriska variabler, men är känslig för outliers och kan påverkas negativt av brus i datan.

K-Means appliceras på samtliga numeriska variabler samt kategoriska variabler efter one-hot encoding. Saknade värden imputeras med median (SimpleImputer) och datan skalas (StandardScaler) för att säkerställa att alla variabler bidrar lika. Antalet kluster fastställs med Elbow-metoden och Silhouette-analys, där $k = 5$ ger en rimlig balans mellan kompaktitet och separation.

Resultatet visar tydliga mönster men även variation i klusterns storlek. Analysen indikerar att bostadspriser påverkas av en kombination av inkomst, befolkningstäthet och geografiskt läge. Hög befolkningstäthet innebär inte nödvändigtvis högre priser, och vissa kluster tyder på att geografisk attraktionskraft har en avgörande betydelse.



Geografisk spridning av K-Means kluster (k=5)

8) Självreflektion

Jag valde klassificeringsproblemet ("Spår B") framför regression ("Spår A") eftersom jag ville fördjupa mig inom klassificering och dess

tillämpningar. Jag har lagt mycket tid på arbetet, särskilt på att försöka förstå de bakomliggande teoretiska aspekterna, vilket också var den mest utmanande delen. Framför allt upplevde jag att avvägningar kring modellval, utvärderingsmått och klassobalans krävde en djupare förståelse än jag initialt hade. Även min begränsade erfarenhet av Scikit-learn innebar vissa svårigheter, men bidrog samtidigt till en tydlig utveckling i min praktiska förståelse av maskininlärning.

Jag bedömer att mitt arbete motsvarar Väl Godkänd då jag visar både bredd och djup inom kursens lärandemål. Jag implementerar och utvärderar flera modeller på ett strukturerat sätt samt använder både övervakad och oövervakad inlärning. Jag motiverar modellval utifrån data och syfte, samt för en kritisk diskussion kring exempelvis klassobalans, threshold-justering och modellernas begränsningar. Detta visar på fördjupad förståelse och självständig analys i linje med VG-kraven.